

Comparative Study of Classical Machine Learning Approaches for Indonesian Local Script Handwritten Recognition

Bintang Nur Fadhlillah¹, Dian Rakhmawati Lestari², Fadhlan Nur Rachman³

I. Problem Statement

Indonesia memiliki kekayaan budaya berupa aksara daerah Nusantara seperti aksara Bali, Jawa, Sunda, hingga Jawi. Namun, kemampuan masyarakat dalam membaca dan menulis aksara ini menurun drastis, mengancam kelestarian warisan intelektual bangsa. Tantangan utama dalam *Handwritten Character Recognition* (HCR) aksara Nusantara adalah struktur karakter yang kompleks dan variasi gaya penulisan tangan yang tinggi. Meskipun *Deep Learning* memiliki akurasi tinggi, model tersebut membutuhkan *resource* komputasi yang besar dan latensi yang sering kali tinggi. Terdapat kebutuhan mendesak untuk mengevaluasi efektivitas metode *Classical Machine Learning* yang lebih ringan namun tetap akurat untuk diimplementasikan pada perangkat dengan spesifikasi terbatas.

II. Dataset Source and Description


1. Dataset: *Indonesian Local Script Characters Handwriting Dataset* (Mendeley Data, 2024). Mencakup 9 aksara: Bali, Batak, Jawa, Jawi, Kawi, Lampung, Lontara, Pallawa, dan Sunda. (Link: <https://data.mendeley.com/datasets/vfj32bpjsf/1>)
2. Data Characteristics: Dataset terdiri dari ribuan sampel gambar karakter tunggal yang telah dipre-proses awal.
3. Preprocessing: Tahapan meliputi *Grayscale conversion*, *Noise Removal*, *Deskewing* (koreksi kemiringan), dan *Resizing* ke ukuran standar (32×32 atau 64×64 piksel) untuk ekstraksi fitur.

III. Initial Plan Model/Methodology

Kami menggunakan pendekatan *Shallow Learning* dengan ekstraksi fitur manual:

1. Baseline Model (Support Vector Machine - SVM)
Menggunakan metode SVM dengan kernel RBF. SVM dipilih sebagai *baseline* karena kemampuannya yang sangat baik dalam menangani klasifikasi data dimensi tinggi (citra) dengan margin optimal. Fitur yang digunakan adalah *Raw Pixel Intensity* yang sudah dinormalisasi.
2. Advanced Model (XGBoost with HOG Feature Extraction)
menggabungkan dan mencoba algoritma *Ensemble Learning* yang kuat dengan teknik ekstraksi fitur visi komputer klasik:
 - Feature Extraction: HOG (*Histogram of Oriented Gradients*) sangat efektif untuk mengenali bentuk dan struktur karakter Abugida karena menangkap distribusi intensitas gradien dan arah tepi.

- Classifier: XGBoost (*Extreme Gradient Boosting*) sebagai bagian dari *Ensemble Learning*, XGBoost akan mengoptimalkan klasifikasi jenis aksara melalui skema *gradient boosting trees* yang efisien dan cepat.
- Hyperparameter Tuning: Melakukan *Grid Search* untuk mencari parameter `learning_rate`, `max_depth`, `n_estimators`, dan berikut untuk *pipeline*-nya:



IV. Evaluation Metrics and Success Criteria

1. Accuracy & Macro Avg F1-Score: Mengukur performa klasifikasi pada kategori aksara untuk memastikan model tidak bias pada kelas tertentu.
2. Inference Latency: Target respon sistem < 100 ms per karakter untuk menjamin pengalaman pengguna yang *seamless*.
3. Deployment: Model akan di-*deploy* menggunakan Streamlit atau FastAPI, memungkinkan pengguna mengunggah gambar tulisan tangan aksara dan mendapatkan prediksi yang instan.
4. User Testing: Melakukan pengujian kepada 10 pengguna eksternal menggunakan *mixed method*, yaitu pertanyaan kualitatif (*feedback*) dan kuantitatif (Skala 1-5) terkait akurasi prediksi dan kemudahan penggunaan antarmuka.

V. References

- Ihsan, A. F. (2024). Indonesian Local Script Characters Handwriting Dataset. Mendeley Data. <https://data.mendeley.com/datasets/vfj32bpjsf/1>
- M. D. Sulistiyo, "Investigating Shallow Learning Methods for Optical Character Recognition of Indonesia's Nusantara Scripts", *J. RESTI (Rekayasa Sist. Teknol. Inf.)*, vol. 9, no. 6, pp. 1538 - 1550, Jan. 2026. <https://jurnal.iaii.or.id/index.php/RESTI/article/view/6648/1200>
- Adilazuarda, Muhammad & Wijanarko, Musa & Susanto, Lucky & Nur'aini, Khumaisa & Wijaya, Derry & Aji, Alham. (2025). NusaAksara: A Multimodal and Multilingual Benchmark for Preserving Indonesian Indigenous Scripts. [2025.acl-long.1377.pdf](https://arxiv.org/abs/2025.01.1377.pdf)
- Revitalization of Ancient Indonesian Characters Research. (2022). Maintenance Efforts in Past 10 Years. ResearchGate.
- Chen, T., & Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining.